



PRODUCTO DE DATOS

OLIST CHURN-SHIELD RETAILER


V1.0.0

Motor predictivo de retención y segmentación RFM,
respaldado por estricta calidad y gobernanza de datos.



Autores:

Joseph Steven Gonzalez Ordoñez
Roberto Carlos Jiménez Castillo
Rosalinda Elizabeth Tenemaza Morales
Angel Patricio Pacheco Jara
Luis Fernando Aucanshala Naula



INDICE

Resumen del Producto de Datos.....	4
1. Alcance del producto de datos.....	5
1.1 Flujo de trabajo detallado	5
2. Análisis de cadena de valor y oportunidad de datos	7
2.1 Actividades de apoyo	7
2.2 Actividades primarias.....	7
2.3 Datos críticos y riesgos si son incorrectos.....	8
2.4 Reflexión de oportunidad	9
3. Ficha DPDS - Data Product Descriptor Specification.....	9
3.1 Identidad del producto.....	10
3.2 Descripción de negocio	10
3.3 Decisiones que habilita.....	11
3.4 Consumidores identificados.....	11
3.5 Puertos de entrada - Input Ports.....	11
3.6 Output Port - Esquema lógico acordado.....	12
3.7 SLA - Acuerdo de Nivel de Servicio del producto	13
3.8 Observabilidad y contacto	13
3.9 Tags y clasificación.....	13
4. Data Contract del producto.....	14
4.1 Partes del contrato	14
4.2 Identificación del contrato	14
4.3 Uso permitido y uso prohibido	15
4.4 Esquema acordado y control de cambios	15
4.5 Gestión de cambios y versionamiento.....	16
4.6 Responsabilidades.....	17
4.7 Resolución de disputas	17
4.8 Firmas y aprobación.....	18
5. Business Case ejecutivo	18
5.1 Propuesta de valor.....	18
5.2 Problema de negocio	18
5.3 Costos actuales de no actuar	19

5.4	Solución propuesta.....	19
5.5	Valor de negocio esperado	20
5.6	Indicadores clave de adopción.....	20
5.7	Roadmap de implementación	21
5.8	Riesgos y mitigación	21
5.9	Solicitud al decisor.....	22
6.	Marco de calidad de datos	22
6.1	Matriz de reglas por dimensión.....	22
6.2	Tablas de calidad propuestas	23
6.3	Fórmula del Data Quality Score	24
7.	Gobierno, catálogo y OpenMetadata.....	25
7.1	Servicio y alcance de ingesta de metadatos	25
7.2	Dominios y subdominios	26
7.3	Glosario inicial.....	26
7.4	Tags y políticas de consumo	27
7.5	RACI de gobierno	28
8.	Linaje esperado de extremo a extremo	28
8.1	Linaje principal de ingesta y Modelado	28
8.2	Linaje de Calidad de Datos.....	29
8.3	Estrategia práctica para el Gobierno en OpenMetadata	29
9.	Plan de implementación y criterios de aceptación	30
9.1	Pasos detallados para cerrar.....	30
9.2	Criterios de aceptación	31
9.3	Handoff.....	31
10.	Referencias consultadas	33
10.1	Referencias Técnicas y Herramientas	33
10.2	Fuentes Metodológicas y Bibliográficas (Arquitectura, ML y Gobierno).....	33
11.	Cierre.....	34

Resumen del Producto de Datos

Olist Churn-Shield Retailer es un producto de datos gobernado de alto valor que transforma la complejidad transaccional del ecosistema Olist en activos analíticos confiables para respaldar decisiones ejecutivas estratégicas, como el análisis de ventas y la predicción de fuga de clientes (*churn*). Apoyado en una arquitectura técnica robusta que abarca desde la ingesta y limpieza con Talend hacia SingleStore, hasta un modelo dimensional en Snowflake consumido vía Power BI, el verdadero núcleo de esta primera fase radica en su marco de negocio y gobernanza.

La iniciativa trasciende la creación de un simple tablero visual para entregar un ecosistema completamente auditable a través de OpenMetadata, donde cada métrica está respaldada por un contrato de datos formal, responsables definidos (*owners*), un linaje transparente y un "Data Quality Score", garantizando a la dirección que cada decisión se tome basándose en métricas exactas, documentadas y comprobables.

Componente	Resultado esperado
Valor de negocio	Identificar proactivamente qué clientes volverán a comprar en los próximos 90 días y descubrir exactamente qué categorías de producto están impulsando la fuga (<i>churn</i>), apalancados en un modelo de segmentación RFM
Valor técnico	Construcción de un ecosistema escalable que integra la ingesta automatizada desde CSVs con Talend, perfilado en SingleStore y un procesamiento ELT hacia un modelo dimensional analítico (estrella) alojado en Snowflake
Valor de gobierno	Visibilidad y transparencia total a través de OpenMetadata, garantizando el linaje desde la extracción original hasta el modelo predictivo y aplicando reglas de calidad en variables críticas (como consistencia de fechas y nulos en <i>review score</i>)
Valor ejecutivo	Despliegue de un <i>Dashboard</i> estratégico en Power BI que no solo muestra métricas pasadas, sino que expone el top de categorías en riesgo de abandono y cruza la predicción de <i>churn</i> con el desempeño de ventas
Valor diferencial	La evolución de un reporte estático a una herramienta de analítica predictiva de alta confianza, capaz de comparar de manera certera el <i>Churn rate</i> mensual predicho frente al real

	(probado en los últimos 3 meses) bajo un pipeline totalmente auditable
--	--

1. Alcance del producto de datos

En esta fase corresponde a la definición formal del producto. Su objetivo es diseñar, documentar y alinear el producto con necesidades de negocio y criterios técnicos antes de iniciar la construcción completa. Esta fase debe generar artefactos reutilizables en una relación formal con cliente.

Elemento	Detalle
Definición del producto	Nombre, propósito, dominio, alcance, problema, usuarios, decisiones que habilita y valor esperado.
Artefactos de negocio	Cadena de valor, selección del producto, business case, beneficios, riesgos y solicitud al decisor.
Artefactos técnicos	DPDS, data contract, inventario de fuentes, output schema, SLA, observabilidad y criterios de aceptación.
Gobierno	Dominios, owners, RACI, glosario, tags, clasificación, catálogo y linaje esperado en OpenMetadata.
Calidad de datos	Reglas candidatas por las 6 dimensiones canónicas: completitud, precisión, consistencia, validez, unicidad y oportunidad.
Preparación para BI	Definición de dashboards y vistas certificadas que se consumirán desde Power BI.

1.1 Flujo de trabajo detallado

El flujo de trabajo del producto Olist Churn-Shield Retailer no solo define las reglas de negocio, sino que se materializa en una arquitectura técnica de procesamiento de datos por capas. A continuación, se detalla cómo los requerimientos y reglas definidas se ejecutan a través de nuestro pipeline automatizado:

1. Identificación e Ingesta de Fuentes (Capa RAW)

Definición: Seleccionar las fuentes de datos transaccionales del ecosistema Olist que aportan valor al producto.

Ejecución en el Pipeline: Los archivos de origen en formato CSV ingresan al flujo mediante el proceso Job load raw, el cual extrae los datos crudos y los carga directamente en nuestra base de datos analítica inicial en SingleStore.

2. Perfilado y Reglas de Calidad (Capa DQ - Data Quality)

Definición: Mapear y ejecutar las reglas de calidad en las 6 dimensiones canónicas (completitud, validez, consistencia, etc.) y definir los KPIs de calidad del dato.

Ejecución en el Pipeline: Esta es la fase central del procesamiento en SingleStore, compuesta por un ciclo de cuatro procesos clave:

- Job Perfilado: Analiza la estructura inicial y el estado de los datos ingresados.
- Job score de calidad: Evalúa los datos contra el contrato de datos para calcular la calificación de confianza (Data Quality Score).
- Job rechazos: Separa y aísla los registros que no cumplen con las reglas críticas de calidad.
- Job implantación de calidad: Aplica las transformaciones y limpieza necesarias para que el dato sea confiable.

3. Modelado Dimensional (Capa MART / Gold)

Definición: Definir la capa MART consolidando el modelo dimensional (hechos y dimensiones) para habilitar los cruces de información.

Ejecución en el Pipeline: Una vez que el dato está limpio y certificado, se ejecuta el Job carga estrella. Este proceso transforma los datos relacionales en un modelo de estrella (Star Schema) y los aloja en el motor analítico final (Snowflake / SingleStore) listos para su explotación.

4. Consumo Analítico y Casos de Uso (Data Product Views)

Definición: Definir los dashboards esperados y habilitar la toma de decisiones ejecutivas orientadas al problema de negocio (ej. prevención de Churn)

Ejecución en el Pipeline: La capa final se bifurca en dos grandes salidas conectadas al modelo de estrella:

- Power BI (Dashboard): Conectado exclusivamente a las vistas certificadas para proveer la visión ejecutiva de ventas, operaciones y nivel de calidad del dato.

- Modelo Predictivo: Alimentado por las variables del modelo (como la segmentación RFM) para predecir qué clientes tienen riesgo de abandono (churn) en los próximos 90 días.

2. Análisis de cadena de valor y oportunidad de datos

La cadena de valor permite detectar dónde los datos generan más impacto en el negocio. Para este caso, se analiza un marketplace de comercio electrónico basado en las fuentes Olist, donde intervienen clientes, pedidos, productos, vendedores, pagos, entregas y reseñas.

2.1 Actividades de apoyo

Actividad de apoyo	Datos que genera	Decisiones que apoya	Sistema / herramienta
Infraestructura de la empresa	Tiempos de pipeline y costos de recursos	Dimensionamiento y viabilidad del ecosistema analítico.	SingleStore, Snowflake y Power BI
Gestión de personas	Asignación de <i>owners</i> en OpenMetadata para tablas y vistas	Auditoría de reglas de calidad y certificación del linaje	OpenMetadata, directorio corporativo, gestión de accesos.
Desarrollo tecnológico	Pipelines en Talend, scripts ELT y el modelo predictivo (RFM y Churn)	Optimización del código y refinamiento de la predicción	Talend Studio, OpenMetadata, Snowflake, Docker Compose.
Aprovisionamiento	Descarga del dataset Olist (Kaggle), drivers y credenciales	Garantizar la disponibilidad de la materia prima y las conexiones	SingleStore, Snowflake, Power BI, OpenMetadata, repositorios.

2.2 Actividades primarias

Eslabón	Dato crítico	Oportunidad de producto
Captura de pedidos	order_id, customer_id, fechas de compra (purchase_timestamp)	Provee la base temporal indispensable para calcular la Recencia (días desde la última compra) y la Frecuencia de la segmentación RFM
Gestión comercial	product_id, nombre de la categoría, precio e ítem.	Alimenta la dimensión dim_product en Snowflake, permitiendo descubrir exactamente cuál es las categorías que más contribuyen a la fuga de clientes.

Pagos	payment_value (monto pagado por el cliente).	Aporta la métrica directa para calcular el Valor Monetario (M), cerrando así los tres pilares del análisis RFM
Operación y entrega	Fechas de entrega (estimada vs. real).	Permite ejecutar las reglas de calidad (DQ) obligatorias para aislar ese ~8% de fechas inconsistentes y evaluar si los retrasos operativos son la causa del abandono
Experiencia de cliente	review_score (calificación de 1 a 5).	Exige auditar el ~3% de valores nulos (regla DQ de completitud) e integra la satisfacción como variable para predecir si el cliente comprará en los próximos 90 días.

2.3 Datos críticos y riesgos si son incorrectos

Dato crítico	Riesgo Técnico	Impacto en el Negocio	Control propuesto (Reglas DQ)
order_purchase_timestamp	No se puede medir correctamente la línea de tiempo de la transacción.	Destruye el cálculo de la Recencia (R) en el modelo RFM. Sin esto, es imposible saber si un cliente está inactivo o predecir si comprará en los próximos 90 días.	Regla de completitud y validación de fechas.
customer_id y order_id	Se rompe la capacidad de rastrear cuántas veces un mismo usuario ha interactuado con la plataforma.	Invalida el cálculo de la Frecuencia (F). Si se duplican o pierden identificadores, el <i>Churn rate</i> mensual predicho será completamente falso.	Regla de unicidad y estricta restricción de no nulos al procesar en SingleStore,
payment_value	Distorsión de los montos reales pagados por tarjeta, boleto o voucher,.	Falsifica el cálculo del Valor Monetario (M) de la segmentación RFM, impidiendo identificar qué clientes de alto valor están en riesgo de fuga.	Reglas de validez (valores > 0, decimales válidos) y consistencia con el costo del ítem más flete,.
product_category_name	Los ítems vendidos quedan huérfanos de agrupación o	Bloquea la entrega de uno de los requerimientos obligatorios: descubrir exactamente el Top 5 de	Cruzar con la tabla de traducción de categorías (product_category_name_translation) y validar dominio permitido.

	categoría comercial.	categorías que más contribuyen al <i>churn</i> .	
review_score	Se deja pasar a la tabla analítica (MART) el ~3% de valores nulos que tiene el dataset original.	El modelo predictivo pierde la variable principal de satisfacción, dificultando que el algoritmo entienda por qué el cliente decide abandonar Olist.	Regla estricta de validez (rango entre 1 y 5) y definir con negocio si los nulos se rechazan o se imputan.
Fechas de entrega (Estimada vs. Real)	Pasa al modelo el ~8% de fechas inconsistentes (ej. fecha de entrega real anterior a la compra).	El algoritmo aprenderá sobre datos sucios, ocultando si un problema logístico (retraso real) fue la verdadera causa de la pérdida del cliente.	Regla DQ de consistencia temporal: aislar registros donde la entrega real sea ilógica frente a la fecha de compra.

2.4 Reflexión de oportunidad

La mayor oportunidad de Olist Churn-Shield Retailer es evolucionar de un reporte reactivo a una herramienta estratégica, predictiva y auditable.

- Anticipación (RFM y Churn): El verdadero valor directivo no es saber cuánto se vendió ayer, sino predecir con exactitud qué clientes volverán a comprar en los próximos 90 días basándose en su comportamiento.
- Acción Inmediata: Cruzar la probabilidad de fuga (churn) con el catálogo para accionar directamente sobre las categorías que están provocando el abandono de la plataforma.
- Confianza Total: Asegurar a la dirección que la predicción es exacta. Al respaldar el algoritmo con reglas de calidad estrictas y linaje en OpenMetadata, se garantiza que los datos sucios originales (fechas ilógicas o nulos) no contaminaron el modelo matemático.

3. Ficha DPDS - Data Product Descriptor Specification

La DPDS describe formalmente la identidad, valor, consumidores, entradas, salidas, SLA, observabilidad y clasificación del producto de datos. Este artefacto es esencial cuando se trabaja con un cliente porque convierte una idea de analítica en un producto con responsabilidades y compromisos claros.

3.1 Identidad del producto

Campo	Valor
Nombre del Producto de Datos	Olist Churn-Shield Retailer
ID único	dp-olist-retail-churn-001
Versión	v1.0.0
Estado	En construcción / Definición de Arquitectura Lógica
Dominio propietario	Analítica Comercial y Retención de Clientes
Subdominios	Segmentación RFM, Rendimiento de Productos (Top Categorías) y Calidad de Datos (DQ)
Data Product Owner	Dirección Comercial / Responsable de Estrategia de Retención
Data Steward	Auditor de Calidad (Responsable de gobernar fechas de entrega y nullos en <i>reviews</i>)
Data Engineer	Desarrollador ELT (Responsable del pipeline Talend, SingleStore y el modelo estrella en Snowflake)
Fecha de creación	15/06/2026
Última actualización	18/06/2026

3.2 Descripción de negocio

Olist Churn-Shield Retailer resuelve la necesidad estratégica de anticipar la fuga de clientes (churn) para permitir acciones de retención proactivas. A través de un modelo predictivo fundamentado en la segmentación RFM (Recencia, Frecuencia, Valor Monetario), el producto responde a la interrogante clave del negocio: identificar con exactitud qué clientes volverán a comprar en los próximos 90 días. A diferencia de un análisis de ventas tradicional, esta solución cruza la probabilidad de abandono con el comportamiento de compra para revelar exactamente qué categorías de producto están impulsando la pérdida de usuarios. Todo este análisis se apoya en un ecosistema técnico auditable que garantiza que cada variable (como los montos de pago, fechas de compra o calificaciones) haya superado estrictas reglas de calidad antes de alimentar la predicción, brindando a la dirección métricas exactas y libres de inconsistencias

3.3 Decisiones que habilita

Tipo de decisión	Decisión habilitada
Estratégica	Prever con exactitud qué clientes volverán a comprar en los próximos 90 días utilizando la segmentación RFM.
Operativa	Ejecutar campañas de retención dirigidas específicamente a los usuarios que el algoritmo marque con alta probabilidad de abandono.
Gobierno	Determinar si el Churn rate predicho en el dashboard es confiable, basándose en el Data Quality Score.

3.4 Consumidores identificados

Consumidor / Rol	Caso de Uso Específico	Frecuencia
CEO / Dirección Comercial	Revisar la tasa de <i>churn</i> mensual predicha vs. real y tomar decisiones estratégicas sobre las categorías en riesgo.	Mensual / Semanal
Equipo de Retención (Marketing)	Consumir la segmentación RFM para ejecutar campañas focalizadas en clientes con alta probabilidad de abandono en los próximos 90 días.	Diario / Semanal
Analista BI	Conectarse desde Power BI <i>únicamente</i> a las vistas certificadas del modelo de estrella para diseñar y mantener el <i>dashboard</i> de ventas y <i>churn</i> .	Diario
Auditor de Calidad (Data Steward)	Monitorear en OpenMetadata el <i>Data Quality Score</i> , asegurando que el modelo no se alimente de fechas ilógicas o nulos en las reseñas.	Diario

3.5 Puertos de entrada - Input Ports

Fuente de datos	Tipo	Sistema origen / destino RAW	Frecuencia
olist_orders_dataset.csv	CSV / batch	raw.orders_g4	Carga batch por ejecución Talend
olist_order_items_dataset.csv	CSV / batch	raw.order_items_g4	Carga batch por ejecución Talend
olist_customers_dataset.csv	CSV / batch	raw.customers_g4	Carga batch por ejecución Talend
olist_order_payments_dataset.csv	CSV / batch	raw.order_payments_g4	Carga batch por ejecución Talend
olist_order_reviews_dataset.csv	CSV / batch	raw.olist_order_reviews_g4	Carga batch por ejecución Talend

olist_products_dataset.csv	CSV / batch	raw.olist_products_g4	Carga batch por ejecución Talend
olist_sellers_dataset.csv	CSV / batch	raw.sellers_g4	Carga batch por ejecución Talend
product_category_name_translation.csv	CSV / batch	raw.product_category_g4	Carga batch por ejecución Talend

3.6 Output Port - Esquema lógico acordado

Campo	Tipo lógico	Uso	Regla de Calidad DQ
order_id	Texto	Base transaccional para calcular la Frecuencia (F).	Unicidad en fact_orders y estrictamente no nulo.
customer_id	Texto	Llave para agrupar compras por cliente y predecir su fuga.	Existencia obligatoria en dim_customer.
purchase_timestamp	Fecha	Define la Recencia (R) (días desde la última compra).	Rango temporal válido (no fechas futuras).
payment_value	Decimal	Determina el Valor Monetario (M) en la matriz RFM.	Mayor a 0 y consistente con la transacción.
category_name	Texto	Variable para agrupar y descubrir las categorías en riesgo de <i>churn</i> .	Dominio válido (traducción de categoría correcta).
review_score	Entero	Variable predictiva clave sobre la satisfacción del cliente.	Rango 1-5 (con política definida para el ~3% de nulos).
is_late_delivery	Booleano	Evalúa si el retraso logístico es la causa principal del abandono.	Consistencia temporal (controlando el ~8% de fechas ilógicas).
rfm_segment	Texto	Agrupación final del cliente calculada por el modelo (Ej. "En Riesgo").	N/A (Campo derivado, validado por lógica de negocio).
churn_probability	Decimal	Salida del modelo: probabilidad de no comprar en los próximos 90 días.	Valor validado entre 0 y 1 (o 0 a 100%).

3.7 SLA - Acuerdo de Nivel de Servicio del producto

Dimensión	Valor Comprometido
Frescura / Oportunidad	Los segmentos RFM y la probabilidad de <i>churn</i> mensual deben estar actualizados y disponibles en Power BI en una hora determinada.
Latencia Batch	El cálculo predictivo y la ingesta completa (Talend → SingleStore → Snowflake) deben procesarse en un tiempo máximo de 60 minutos.
Complejidad	Cero nulos (100% de completitud) en <i>customer_id</i> y <i>order_id</i> para no romper el cálculo RFM. Tolerancia estricta y control del ~3% de nulos en <i>review_score</i> .
Consistencia	Tratamiento e identificación garantizada del ~8% de fechas de entrega inconsistentes antes de que contaminen el entrenamiento del modelo.
Observabilidad	Cada carga de datos debe registrar su <i>Data Quality Score</i> y su linaje de forma 100% auditable a través de OpenMetadata.

3.8 Observabilidad y contacto

Campo	Valor propuesto
Canal de reportes	Google Meet / whatsapp
Tiempo de respuesta ante incidentes	Crítico: 2 horas. Alto: 8 horas. Medio: 24 horas.
URL del catálogo	OpenMetadata - servicio <i>singlestore_olist_analytics</i> .
Enlace al lineage	Vista de linaje en OpenMetadata para tablas RAW, STG, MART.
Documentación adicional	Diccionario de datos, reglas DQ, data contract, glosario, matriz RACI y manual de consumo.
Herramienta de validación técnica	SingleStore.

3.9 Tags y clasificación

Categoría	Tags / clasificación
Capa	Bronze para RAW, Silver para STG, Gold para MART, Certified para vistas.
Negocio	ecommerce, ventas, pedidos, pagos, clientes, productos, entregas, reseñas.

Calidad	DQ Monitored, Data Quality, Rejects, Findings, Data Trust.
Criticidad	Business Critical para vistas ejecutivas y métricas usadas por CEO.
Sensibilidad	Internal; PII Candidate para identificadores de clientes aunque el dataset esté anonimizado.
Regulación	Considerar principios de protección de datos y minimización cuando se trabaje con datos reales de clientes.

4. Data Contract del producto

El Data Contract formaliza los acuerdos entre el productor y los consumidores del producto de datos. Define el esquema, las reglas de calidad, los SLAs, las responsabilidades y el versionamiento.

4.1 Partes del contrato

Rol	Área / nombre	Responsable
Productor	Equipo de Datos / Ingeniería de Datos	Data Engineer responsable de Talend y SingleStore, Snowflake
Productor de negocio	Analítica Comercial y Operativa	Data Product Owner
Consumidor	CEO, Comercial, Operaciones, Atención al Cliente y BI	Responsables de cada área consumidora
Data Steward	Gobierno de Datos / BI	Data Steward asignado
Plataforma de gobierno	OpenMetadata	Responsable de gobierno y catálogo

4.2 Identificación del contrato

Campo	Valor
Código del contrato	DC-ecommerce-olist-churn-360-001
Nombre del producto	Olist Churn-Shield Retailer
ID del producto	dp-olist-retail-churn-001
Versión del contrato	v1.0.0
Vigencia	Desde hasta nueva versión aprobada
Estado	Borrador para aprobación

4.3 Uso permitido y uso prohibido

Tipo	Descripción
Uso permitido	Consumir la probabilidad de <i>churn</i> y los segmentos RFM exclusivamente desde las vistas certificadas en Power BI para ejecutar campañas de retención de clientes.
Uso permitido	Utilizar el tablero para identificar las categorías en riesgo e intervenir proactivamente en el inventario o la logística.
Uso permitido	Auditar el <i>Data Quality Score</i> en OpenMetadata para verificar que el modelo no se entrenó con el ~8% de fechas inconsistentes ni el ~3% de reseñas nulas del dataset original.
Uso prohibido	Conectar Power BI o cualquier herramienta de BI a las tablas crudas (RAW) o de staging (STG), ya que contienen datos anómalos que distorsionan la predicción.
Uso prohibido	Alterar la fórmula de la segmentación RFM o los umbrales de probabilidad de <i>churn</i> directamente en los tableros de visualización; todo cálculo debe venir del modelo centralizado.
Uso prohibido	Utilizar los identificadores de clientes (<i>customer_id</i>) de la capa analítica para fines distintos a las estrategias comerciales y de retención aprobadas.

4.4 Esquema acordado y control de cambios

Campo Acordado	Tipo	Uso en el Modelo (Reto Churn y RFM)	¿Puede cambiar sin aviso?
customer_id	Texto	Llave para predecir la fuga por cliente.	No. Rompe el seguimiento histórico.

order_purchase_timestamp	Fecha	Define la Recencia (R) del modelo RFM.	No. Altera la línea temporal de la predicción.
order_id	Texto	Base transaccional para la Frecuencia (F).	No. Generaría duplicados en el recuento.
payment_value	Decimal	Define el Valor Monetario (M).	No. Falsifica el perfil de ingresos.
product_category_name	Texto	Agrupar ventas para descubrir las categorías con más <i>churn</i> .	Sí, opcional. Sujeto a actualizaciones del catálogo.
review_score	Entero	Predictor clave de satisfacción para el algoritmo.	No. Un cambio de formato o dominio invalida el modelo.
is_late_delivery	Booleano	Predictor derivado de auditar el ~8% de fechas inconsistentes.	No.
churn_probability	Decimal	KPI predictivo final entregado al <i>dashboard</i> en Power BI.	No. Modificar el cálculo requiere un nuevo contrato de datos.

4.5 Gestión de cambios y versionamiento

Tipo de cambio	¿Requiere nuevo contrato?	Aviso previo / Aprobación
Breaking change estructural: Eliminar customer_id, cambiar formato de purchase_timestamp o payment_value (rompe el cálculo de RFM).	Sí	15 días o aprobación explícita.
Non-breaking change: Añadir una nueva variable opcional para el modelo.	No	5 días.
Fix de calidad (DQ): Corrección en el script que limpia el ~8% de fechas de entrega inconsistentes.	No	24 horas.
Cambio de latencia/frecuencia: Alterar el procesamiento Batch de Talend/Snowflake que alimenta Power BI a primera hora.	Sí	7 días.

Cambio en modelo o KPI: Modificar los umbrales matemáticos de la segmentación RFM o la fórmula de probabilidad de <i>churn</i> .	Sí	Aprobación estricta de Dirección Comercial (Product Owner) y Data Steward.
Cambio en Reglas DQ críticas: Cambiar la política de rechazo o imputación para el ~3% de nulos en <code>review_score</code> .	Sí	Aprobación del Data Steward.

4.6 Responsabilidades

Responsabilidad	Productor	Consumidor	Data Steward
Mantener esquema acordado	Sí	No	Supervisa
Consumir vistas certificadas	No	Sí	Supervisa
Reportar problemas de calidad	Sí	Sí	Sí
Documentar términos de negocio	Apoya	Apoya	Responsable
Notificar cambios	Sí	No	Valida
Escalar incidentes	Sí	Sí	Responsable
Revisar contrato periódicamente	Sí	Sí	Sí

4.7 Resolución de disputas

Paso	Descripción
Paso 1	El consumidor reporta el problema por el canal oficial indicando dashboard, vista, KPI, fecha y evidencia.
Paso 2	El productor revisa <code>run_id</code> , auditoría, reglas DQ y linaje para determinar origen del problema.
Paso 3	Si el problema es de definición de negocio, se escala al Data Steward y Product Owner.
Paso 4	Se emite resolución: corrección técnica, cambio de regla, cambio de contrato o aceptación de excepción.
Paso 5	Se actualiza OpenMetadata, y documentación del producto.

4.8 Firmas y aprobación

Rol	Nombre / Área	Firma	Fecha
Data Product Owner	Gerencia Comercial / Operaciones		15/06/2026
Representante consumidor	CEO / BI / Operaciones		15/06/2026
Data Steward	Gobierno de Datos / BI		15/06/2026
Data Engineer	Equipo técnico		15/06/2026

5. Business Case ejecutivo

El business case traduce el producto de datos a valor empresarial. Su objetivo es demostrar por qué conviene invertir tiempo, herramientas y personas en Olist Churn-Shield Retailer.

5.1 Propuesta de valor

Campo	Valor
Empresa / contexto	Marketplace de comercio electrónico basado en fuentes Olist
Dominio	Analítica Comercial y Operativa
Producto	Olist Churn-Shield Retailer
Elaborado por	Joseph Steven Gonzalez Ordoñez Roberto Carlos Jiménez Castillo Rosalinda Elizabeth Tenemaza Morales Angel Patricio Pacheco Jara Luis Fernando Aucanshala Naula
Fecha	15/06/2026

5.2 Problema de negocio

Pregunta	Respuesta
¿Qué decisión no se puede tomar bien hoy?	No es posible predecir qué clientes abandonarán la plataforma (<i>churn</i>) en los próximos 90 días, ni aislar qué categorías específicas de producto están provocando esa fuga.
¿A quién afecta?	CEO, Dirección Comercial y Equipo de Retención (Marketing).
¿Con qué frecuencia ocurre?	Mensualmente, al intentar proyectar ingresos futuros y lanzar campañas de retención.

¿Qué cuesta no tener este dato gobernado?	Tomar decisiones basadas en un ~8% de entregas inconsistentes y ~3% de reseñas nulas, lo que arruina el cálculo RFM y genera falsas predicciones de fuga.
---	---

5.3 Costos actuales de no actuar

Tipo de costo	Descripción del Impacto
Tiempo perdido	Analistas y científicos de datos gastan horas limpiando manualmente las anomalías temporales de Olist en lugar de optimizar el modelo predictivo.
Decisiones equivocadas	Desperdiciar presupuesto de marketing en clientes que ya abandonaron Olist definitivamente por problemas logísticos ocultos.
Riesgo operativo	Mantener activos en el catálogo productos o vendedores que están impulsando silenciosamente la pérdida de usuarios sin que la empresa lo sepa.
Riesgo de gobierno	La dirección rechazará el modelo de <i>churn</i> por considerarlo una "caja negra" si no puede ver su <i>Data Quality Score</i> y linaje en OpenMetadata.
Oportunidad perdida	Seguir operando con tableros reactivos (viendo lo que ya pasó) en lugar de intervenir proactivamente para asegurar recompras en los próximos meses.

5.4 Solución propuesta

Olist Churn-Shield Retailer entrega vistas certificadas y dashboards ejecutivos construidos sobre una arquitectura gobernada. Cada KPI proviene de fuentes catalogadas, transformaciones documentadas, reglas de calidad y linaje visible en OpenMetadata.

Pregunta	Respuesta
¿Qué entrega el producto?	Un modelo predictivo de <i>churn</i> y segmentación RFM, integrado en un <i>dashboard</i> que revela a los clientes en riesgo y las categorías que impulsan el abandono.
¿Quién lo produce?	El desarrollador/ingeniero de datos mediante un pipeline orquestado: Ingesta en Talend → Perfilado y calidad en SingleStore → Modelo dimensional en Snowflake.
¿Quién lo consume?	CEO, Dirección Comercial y el equipo de Retención (Marketing).
¿Dónde se gobierna?	En OpenMetadata, donde se audita el linaje completo y se asegura que el ~8% de fechas inconsistentes y el ~3% de reseñas nulas no contaminen la predicción.

¿Dónde se visualiza?	En Power BI, consumiendo estricta y únicamente las vistas certificadas predictivas alojadas en la capa analítica.
----------------------	---

5.5 Valor de negocio esperado

Beneficio	Métrica de éxito (KPI)	Plazo esperado
Retención proactiva de clientes	Reducir la pérdida accionando estratégicamente sobre en las categorías marcadas con mayor riesgo en los próximos 90 días.	1 a 2 meses
Confianza ejecutiva en la predicción	<i>Data Quality Score</i> $\geq 95\%$ visible en el <i>dashboard</i> , garantizando que el algoritmo fue entrenado con datos aislados de anomalías nativas de Olist.	1 mes
Reducción de tiempo al insight	Pasar de cálculos manuales a visualizar diariamente el <i>Churn rate</i> mensual predicho vs. real (probado como <i>test set</i>) de forma automatizada.	1 mes
Gobernanza del modelo predictivo	100% de las vistas que alimentan el algoritmo con <i>owner</i> asignado, glosario, <i>tags</i> y linaje auditable de extremo a extremo.	1 a 2 meses

5.6 Indicadores clave de adopción

Indicador	Valor objetivo
Adopción de Negocio	El 80% del equipo comercial o de retención usa el <i>dashboard</i> semanalmente para actuar sobre las categorías en riesgo de abandono.
Tiempo al insight	Reducir el tiempo de horas de limpieza manual a visualizar la probabilidad de fuga en menos de 10 minutos.
Confianza (Data Trust)	Mantener un <i>Data Quality Score</i> $\geq 95\%$ visible en Power BI, asegurando al usuario que la predicción es exacta.
Cobertura de Gobierno	100% de las variables clave del RFM y <i>Churn</i> documentadas con <i>tags</i> , glosario y <i>owners</i> en OpenMetadata.

5.7 Roadmap de implementación

Fase	Actividades clave del Reto	Duración
Definición	Firma del <i>Data Contract</i> , DPDS y definición de reglas DQ para controlar fechas ilógicas y nulos en las <i>reviews</i> .	1 día
Ingesta (RAW)	Creación de <i>pipelines</i> automatizados en Talend extrayendo los CSVs de Olist hacia SingleStore.	6 horas
Calidad (DQ)	Perfilado, aislamiento de registros anómalos (~8% de entregas inconsistentes) y cálculo del <i>DQ Score</i> en SingleStore.	20 horas
Modelado y ML	Scripts ELT hacia Snowflake, construcción del modelo estrella, cálculo RFM y ejecución del algoritmo de <i>churn</i> .	1 día
Gobierno	Ingesta de metadatos, glosario y mapeo del linaje completo (Talend -> SingleStore -> Snowflake) en OpenMetadata.	8 horas
Visualización	Despliegue del <i>dashboard</i> predictivo en Power BI conectado exclusivamente a las vistas certificadas.	8 horas

5.8 Riesgos y mitigación

Riesgo Técnico / Negocio	Probabilidad / Impacto	Mitigación
Limpieza Deficiente: El ~8% de fechas de entrega ilógicas y ~3% de <i>reviews</i> nulos arruinan el cálculo de la Recencia y el modelo RFM.	Alta / Alto	Implementar y forzar reglas DQ críticas en la capa Staging (SingleStore) antes de que la data alimente a Snowflake.
Ruptura del Linaje: OpenMetadata no detecta automáticamente las transformaciones y flujos creados en Talend.	Alta / Medio	Crear entidades lógicas de <i>pipeline</i> o usar la API para documentar el linaje manual y no perder la trazabilidad de extremo a extremo.
Rechazo por "Caja Negra": Los ejecutivos no confían en el algoritmo de <i>churn</i> mensual predicho vs. real.	Media / Medio	Exponer el <i>Data Quality Score</i> y el glosario matemático directamente en Power BI y OpenMetadata para hacerlo 100% transparente.
Consumo No Certificado: Analistas conectando Power BI directamente a las tablas crudas de SingleStore (saltándose la lógica RFM).	Media / Alto	Aplicar políticas estrictas del <i>Data Contract</i> : Power BI solo tendrá permisos para consumir las vistas predictivas certificadas.

5.9 Solicitud al decisor

Recurso / Decisión Solicitada	Detalle	Justificación Estratégica
Aprobación del producto	Validar el inicio oficial de Olist Churn-Shield Retailer.	Dar el salto directivo de ver "lo que ya pasó" a predecir qué clientes se fugarán en los próximos 90 días.
Infraestructura técnica	Autorizar el aprovisionamiento y cómputo para Talend, SingleStore, Snowflake y Power BI.	Son los motores necesarios para procesar grandes volúmenes transaccionales y ejecutar el algoritmo matemáticamente.
Gobierno de Datos	Nombrar formalmente un <i>Data Steward</i> y usar OpenMetadata como catálogo central.	Es indispensable para auditar que el ~8% de fechas de entrega ilógicas o nulos no contaminen la predicción.
Compromiso Operativo	Acuerdo con Marketing y Comercial para accionar los <i>insights</i> del <i>dashboard</i> .	El modelo no retiene clientes por sí solo; el negocio debe ejecutar campañas basándose en las categorías en riesgo detectadas.

6. Marco de calidad de datos

El producto usará las seis dimensiones canónicas de calidad de datos: completitud, precisión/exactitud, consistencia, validez, unicidad y oportunidad. Cada dimensión tendrá reglas candidatas, métricas, umbrales, severidad y acciones esperadas.

6.1 Matriz de reglas por dimensión

Dimensión	Reglas candidatas	Tablas / campos	Acción
Completitud	order_id, customer_id, purchase_ts, price, payment_value y review_score no nulos cuando apliquen.	orders, items, payments, reviews	Registrar métrica; rechazar si afecta clave crítica.
Precisión / exactitud	Fechas convertibles, zip numérico, price/payment decimal válido, review_score entero.	customers, orders, items, payments, reviews	Marcar findings y enviar a rejects si impide cálculo.

Consistencia	customer_id en orders existe en customers; order_id en items/payments/reviews existe en orders; delivered tiene fecha de entrega.	orders, customers, items, payments, reviews	Bloquear certificación si falla en reglas críticas.
Validez	order_status y payment_type en dominios permitidos; review_score entre 1 y 5; price > 0; freight >= 0.	orders, payments, reviews, items	Registrar métrica por dominio y rechazar registros inválidos críticos.
Unicidad	order_id único, customer_id único, product_id único, review_id único, order_id único en fact orders.	RAW, STG, MART	Analizar duplicados y evitar doble conteo en MART.
Oportunidad	RAW, STG, DQ y MART ejecutados dentro del SLA; última ejecución exitosa disponible.	_load_ts, _load_run	Notificar data stale y marcar dashboard como no actualizado.

6.2 Tablas de calidad propuestas

Tabla (STG)	Propósito crítico en el Modelo
customers_g4	Llave maestra unificada; agrupa todo el comportamiento para predecir la fuga por cliente.
orders_g4	Base temporal del modelo; calcula la Recencia (R) y audita el ~8% de fechas de entrega ilógicas.
order_items_g4	Granularidad de la compra; permite vincular el abandono del cliente con productos específicos.
order_payments_g4	Define el monto exacto validado, alimentando la variable de Valor Monetario (M) del RFM.
order_reviews_g4	Predictor clave de satisfacción; sujeta a reglas de calidad para aislar el ~3% de reseñas nulas.
product_g4	Catálogo base depurado; indispensable para identificar los artículos exactos que provocan pérdida de usuarios.
product_category_g4	Agrupación estratégica; consolida los datos para revelar el Top 5 de categorías en riesgo en Power BI.

sellers_g4	Dimensión cruzada; permite evaluar si vendedores específicos están impulsando el <i>churn</i> por mal servicio.
geolocation_g4	Dimensión espacial; ayuda a modelar si los retrasos logísticos (y la fuga) se concentran en ciertas regiones.
dq_profile_g4	Perfilado técnico; escanea automáticamente la volumetría y los porcentajes de nulos en la ingesta.
dq_findings_g4	Repositorio de hallazgos; aísla los registros anómalos que rompen las reglas antes de que entren al modelo dimensional.
dq_scoring_g4	Tabla de confianza ejecutiva; calcula el <i>Data Quality Score</i> final para demostrar que la predicción no usó datos basura.

6.3 Fórmula del Data Quality Score

El Data Quality Score consolida la calidad en un indicador ejecutivo. Se calcula como suma ponderada de los scores por dimensión.

Dimensión	Peso propuesto	Justificación
Compleitud	25%	Sin campos críticos no se pueden relacionar entidades ni calcular KPIs.
Consistencia	20%	Garantiza coherencia entre pedidos, clientes, pagos, ítems y reseñas.
Validez	20%	Evita valores fuera de dominio o rangos imposibles.
Unicidad	15%	Previene doble conteo de pedidos, clientes e ingresos.
Precisión / exactitud	10%	Asegura formatos y valores técnicamente interpretables.
Oportunidad	10%	Garantiza que el producto esté actualizado a tiempo.

$$\text{Data Quality Score} = (\text{Compleitud} * 0.25) + (\text{Consistencia} * 0.20) + (\text{Validez} * 0.20) + (\text{Unicidad} * 0.15) + (\text{Precisión} * 0.10) + (\text{Oportunidad} * 0.10)$$

Rango	Estado	Uso recomendado
95 - 100	Confiable	Puede usarse en decisión ejecutiva.
90 - 94.99	Requiere revisión	Puede usarse con advertencia.

80 - 89.99	Riesgo medio	Requiere análisis antes de presentar a dirección.
< 80	No recomendado	No usar para decisión ejecutiva hasta remediar.

7. Gobierno, catálogo y OpenMetadata

OpenMetadata será la capa de gobierno del producto. Allí se documentarán servicios, bases, tablas, columnas, owners, dominios, glosario, tags, clasificaciones, pruebas de calidad, métricas y linaje. Como SingleStore y Snowflake puede conectarse mediante protocolo compatible con MySQL en muchos escenarios, la estrategia inicial será validarlo mediante un servicio tipo MySQL/SingleStore/Snowflake según la conectividad disponible en el ambiente.

7.1 Servicio y alcance de ingesta de metadatos

Elemento en OpenMetadata	Alcance Estratégico (Olist Churn-Shield)
Nombre del servicio y conexión	singlestore_olist_analytics (Conexión compatible con MySQL hacia SingleStore).
Tablas a catalogar	Capas RAW, Staging (stg_g4), tablas de rechazos/calidad y exclusivamente las vistas certificadas que consumirá Power BI.
Ingesta de metadatos (Metadata Ingestion)	Descubrimiento y actualización automática del diccionario de datos para las variables matemáticas predictivas (Recencia, Frecuencia, Valor Monetario y <i>Churn</i>).
Perfilado (Profiler)	Escaneo de distribución y volumetría para auditar continuamente que los valores nulos en la variable predictiva review_score se mantengan controlados (~3%).
Calidad de Datos (Data Quality)	Registro automático en OpenMetadata de las reglas fallidas y rechazos generados al detectar el ~8% de fechas de entrega ilógicas.
Linaje (Lineage)	Trazabilidad del flujo completo: captura desde la ingesta de los CSVs en Talend, la limpieza en SingleStore y el modelo en Snowflake, hasta el <i>dashboard</i> final.

7.2 Dominios y subdominios

Dominio / Subdominio	Enfoque estratégico en el Reto (Churn y RFM)	Activos asociados (Capa STG_g4 / Certificadas)
Clientes	Llave maestra unificada; agrupa todo el comportamiento para calcular la matriz RFM y la probabilidad de abandono por usuario.	customers_g4, geolocation_g4.
Reseñas y Satisfacción	Predictor clave de fuga; requiere auditoría estricta de calidad para garantizar el tratamiento del ~3% de reseñas nulas.	order_reviews_g4, dq_findings_g4.
Logística y Envíos	Analiza los retrasos logísticos para evaluar si son la causa principal del <i>churn</i> , aislando el ~8% de fechas inconsistentes.	orders_g4 (fechas estimadas vs reales).
Marketing	Dominio consumidor; utiliza los segmentos RFM predictivos para ejecutar campañas proactivas de retención de clientes.	Vistas certificadas de segmentación.
Pagos	Base monetaria estricta; alimenta directamente la variable de Valor Monetario (M) del modelo RFM.	order_payments_g4.
Catálogo de Productos	Agrupación analítica; consolida las dimensiones para revelar las categorías que impulsan la fuga de clientes en Power BI.	product_g4, product_category_g4.
Ventas y Órdenes	Base transaccional y temporal; calcula la Frecuencia (F) y la Recencia (R) (días desde la última compra).	orders_g4, order_items_g4.
Vendedores	Dimensión de evaluación cruzada; permite investigar si vendedores específicos contribuyen negativamente a la pérdida de clientes.	sellers_g4.

7.3 Glosario inicial

Término	Definición orientada al Reto	Uso en el Modelo / Activo
Churn (Fuga de Clientes)	Probabilidad matemática de que un usuario no vuelva a comprar en los próximos 90 días.	Métrica estrella (churn_probability) visualizada por la dirección en Power BI.

Segmentación RFM	Matriz analítica que clasifica a la base de clientes según tres variables: Recencia, Frecuencia y Valor Monetario.	Segmento (rfm_segment) que indica a Marketing a quién contactar para retener.
Recencia (R)	Días transcurridos desde la última compra válida de un usuario.	Variable RFM que depende de aislar el ~8% de fechas inconsistentes de la fuente original.
Satisfacción (Review Score)	Calificación de 1 a 5 otorgada por el cliente; predictor crítico para el algoritmo de fuga.	Variable filtrada por reglas DQ para controlar el ~3% de nulos.
Categoría en Riesgo	Agrupación de productos que el algoritmo identifica como detonante principal de los abandonos.	KPI expuesto como "Top de Categorías" para tomar decisiones sobre el catálogo.
Data Quality Score (DQS)	Índice porcentual que mide la confiabilidad de los datos usados para entrenar la predicción.	Expuesto en el dashboard para que el CEO confíe en que el modelo no es una "caja negra".
Vista Certificada	Tabla analítica final, procesada, validada y catalogada en OpenMetadata, lista para el consumo.	Único activo que Power BI tiene permitido consultar (prohibido usar tablas RAW/STG).
Registro Rechazado (Rejects)	Fila de datos (ej. un pedido con fecha de entrega ilógica) excluida para no contaminar el cálculo RFM.	Aislado en la tabla dq_findings_g4 y stg_rejects.

7.4 Tags y políticas de consumo

Tag / Política	Aplicación Estratégica
Bronze / Silver / Gold	Clasifican la madurez del dato: desde los CSVs crudos de Olist (Bronze), pasando por la limpieza de anomalías temporales (Silver), hasta el cálculo matricial de RFM y <i>Churn</i> (Gold).
Certified	Etiqueta exclusiva para las vistas predictivas finales que alimentan Power BI; garantiza a la dirección que el tablero usa el modelo algorítmico oficial.
DQ Monitored	Marca los activos que están siendo auditados activamente en SingleStore para controlar el 3% de reseñas nulas y el 8% de fechas inconsistentes.
Business Critical	Protege el KPI estrella (<i>Churn rate</i> predictivo y Top 5 de categorías en riesgo); alerta al equipo técnico que una falla aquí impacta directamente la toma de decisiones del CEO.

PII Candidate	Control de acceso y seguridad sobre variables sensibles como el customer_id y la ubicación, garantizando privacidad en el perfilado.
Política: Do Not Use Directly	Prohibición absoluta para analistas de conectar herramientas de BI a tablas crudas (RAW) o en proceso (STG), evitando que los datos sucios arruinen las predicciones comerciales.

7.5 RACI de gobierno

Actividad	CEO	Product Owner	Data Steward	Data Engineer	BI Analyst
Definir KPIs	A	R	C	C	C
Definir reglas DQ	I	A	R	R	C
Construir pipelines	I	C	C	R	I
Crear MART y vistas	I	C	C	R	C
Documentar en OpenMetadata	I	C	R	R	C
Crear dashboards	C	A	C	C	R
Aprobar producto	A	R	C	C	C

Leyenda: R = Responsable, A = Accountable, C = Consulted, I = Informed.

8. Linaje esperado de extremo a extremo

El linaje de datos es fundamental para garantizar la transparencia del producto de datos "Olist Churn-Shield Retailer". Permite demostrar al jurado y a los líderes de negocio (como el CEO y la Dirección Comercial) que las métricas de segmentación y las predicciones de abandono provienen de un flujo auditable, gobernado y de alta calidad.

8.1 Linaje principal de ingesta y Modelado

CSVs de Kaggle (olist_orders_dataset, olist_customers_dataset, olist_order_items, etc.)

-> Pipeline Talend (Ingesta automatizada)

- > Base de datos SingleStore (Capa RAW y Staging)
- > Procesamiento ELT
- > Snowflake (Modelo dimensional: fact_orders, dim_customer, dim_product)
- > Modelo de Segmentación RFM y Probabilidad de Churn
- > Power BI (Dashboard de retención y top 5 categorías en riesgo)

8.2 Linaje de Calidad de Datos

Fuentes Olist originales (con anomalías de origen: ~3% nulos en reviews, ~8% fechas inconsistentes)

- > Job de Perfilado en SingleStore (Capa DQ)
- > Ejecución de Reglas DQ (Complejidad, rango temporal válido, unicidad de IDs)
- > Job Score de Calidad (Cálculo del Data Quality Score)
- > Aislamiento de rechazos (Registros ilógicos bloqueados)
- > Power BI (Score de Calidad y Confianza visible para ejecutivos)

8.3 Estrategia práctica para el Gobierno en OpenMetadata

- **Ingesta centralizada:** Ingerir metadatos y catalogar todo el linaje para asegurar una visibilidad completa desde la extracción en Talend, el paso por SingleStore, hasta el modelo predictivo en Snowflake.
- **Auditoría de reglas DQ:** Registrar y mapear las pruebas de calidad (ej. validación de fechas de entrega y reseñas) en el catálogo para demostrar que los datos sucios no contaminaron el algoritmo.
- **Control de consumo:** Etiquetar las vistas analíticas finales como certificadas (Certified / Business Critical) y establecer un contrato de datos que prohíba estrictamente conectar tableros a la capa RAW o de staging.
- **Glosario y transparencia:** Vincular términos del glosario de negocio y reglas matemáticas en OpenMetadata para mitigar el riesgo de que la directiva rechace el modelo percibiéndolo como una "caja negra".
- **Asignación de roles:** Definir a un *Data Steward* que utilice el catálogo para monitorear el score de calidad y certificar los datos antes de que lleguen a la capa de consumo.

9. Plan de implementación y criterios de aceptación

9.1 Pasos detallados para cerrar

- **Validar el nombre oficial y su ID:** Aprobar el nombre oficial **Olist Churn-Shield Retailer** y su identificador único **dp-olist-retail-churn-001**.
- **Confirmar el dominio principal:** Validar que el producto pertenezca al dominio principal de Analítica Comercial y Retención de Clientes, con subdominios enfocados en Segmentación RFM y Calidad de Datos.
- **Validar usuarios consumidores:** Confirmar los perfiles clave: CEO / Dirección Comercial, Equipo de Retención (Marketing), Analista BI, Auditor de Calidad (Data Steward) y Data Engineer / Desarrollador ELT.
- **Confirmar fuentes V1:** Validar la ingesta batch inicial de los archivos CSV: orders, order_items, customers, payments, reviews y products.
- **Confirmar fuentes V2:** Aprobar para fases posteriores la ingesta de las fuentes: sellers y la tabla de traducción product_category_name_translation.
- **Aprobar la arquitectura lógica:** Validar el pipeline técnico:
CSV
-> Extracción con Talend -> SingleStore (Capas RAW, STG y DQ)
-> Snowflake (Capa MART dimensional)
-> Power BI, manteniendo OpenMetadata como plataforma de gobierno transversal.
- **Aprobar KPIs ejecutivos y de calidad:** Confirmar los indicadores métricos principales: el Churn rate mensual predicho vs. real, el top 5 de categorías en riesgo de abandono y el Data Quality Score ($\geq 95\%$) para garantizar la confianza ejecutiva.
- **Aprobar reglas DQ candidatas por las seis dimensiones:** Mapear y aprobar las reglas de completitud, precisión, consistencia, validez, unicidad y oportunidad, haciendo énfasis crítico en aislar el ~8% de fechas de entrega inconsistentes y controlar el ~3% de nulos en las reseñas (review_score).
- **Aprobar el Data Contract v1.0.0:** Formalizar y firmar el contrato de datos bajo el código de identificación DC-ecommerce-olist-churn-360-001, asegurando las políticas de uso permitido (ej. conectar Power BI solo a vistas certificadas) y uso prohibido.
- **Aprobar el Business Case y decisión solicitada:** Autorizar el retorno de inversión justificando la transición de reportes reactivos a predicción proactiva (identificar abandono en los próximos 90

días). Aprobar la infraestructura técnica (Talend, SingleStore, Snowflake, Power BI), el rol del Data Steward y el compromiso del negocio para accionar campañas.

- **Registrar en OpenMetadata la estructura inicial:** Catalogar la información base: dominios, términos del glosario, tags (Bronze, Silver, Gold, Certified, Business Critical) y la asignación de owners.
- **Preparar transición a Fase 2:** Realizar el *handoff* (traspaso) con el inventario de las Fuentes V1, el diseño para las capas RAW y STG, la conversión de las reglas DQ a código (YAML/SQL ejecutable) y la preparación de los jobs de Talend faltantes para la ingesta.

9.2 Criterios de aceptación

Criterio	Estado esperado
Producto definido	Nombre, ID, propósito, dominio y consumidores aprobados.
DPDS completada	Ficha técnica con entradas, salidas, SLA, observabilidad y tags.
Data Contract completado	Esquema, uso permitido, responsabilidades y versionamiento documentados.
Business Case completado	Problema, solución, valor, adopción, riesgos y decisión solicitada documentados.
KPIs definidos	KPIs ejecutivos, comerciales, operativos, cliente y calidad identificados.
Reglas DQ definidas	Reglas candidatas mapeadas a las seis dimensiones.
Gobierno definido	Dominios, glosario, owners, tags y RACI iniciales listos.
Linaje esperado	Rutas principales de linaje documentadas para ventas, cliente y calidad.

9.3 Handoff

Elemento de salida	Uso específico
Fuentes V1	Crear y validar las tablas en la capa RAW (en SingleStore) y construir los <i>jobs</i> de Talend para automatizar la ingesta de los CSVs críticos (orders, customers, payments, reviews, items, products) necesarios para conocer el historial del cliente.
Output schema	Diseñar las vistas de <i>Staging</i> (STG), el modelo dimensional en estrella (MART) en Snowflake y materializar los campos del contrato de datos en vistas certificadas (dp_*), incluyendo específicamente rfm_segment y churn_probability.

Reglas DQ	Convertir las reglas candidatas en código SQL y YAML ejecutable dentro de SingleStore, priorizando los <i>scripts</i> que aíslan el ~8% de fechas de entrega ilógicas y controlan el ~3% de nulos en las reseñas para que no contaminen el modelo.
SLA	Configurar métricas para asegurar que la ingesta, la limpieza de datos y la predicción del algoritmo tomen un máximo de 60 minutos de procesamiento <i>batch</i> .
Tags y dominios	Configurar en OpenMetadata la estructura inicial: crear el dominio "Analítica Comercial y Retención" y aplicar las etiquetas de capa (Bronze, Silver, Gold) y criticidad (Certified, Business Critical) a los activos del modelo RFM.
Linaje esperado	Construir las relaciones técnicas y documentarlas en OpenMetadata para demostrar visualmente la cadena de custodia: desde la extracción en Talend, el perfilado en SingleStore, hasta la segmentación en Snowflake.
Dashboards esperados	Diseñar el tablero ejecutivo en Power BI conectándolo estrictamente a las vistas certificadas, para visualizar la predicción de <i>churn rate</i> mensual y accionar sobre el top de categorías que impulsan el abandono.

10. Referencias consultadas

10.1 Referencias Técnicas y Herramientas

Fuente / Herramienta	Referencia y Propósito en el Proyecto	Enlace (Link)
OpenMetadata	Documentación oficial para la configuración del Glosario de gobierno de datos.	OpenMetadata - Glossary
OpenMetadata	Configuración del conector compatible de MySQL para ingestar metadatos desde SingleStore.	OpenMetadata - MySQL Connector
OpenMetadata	Guía de Data Quality para auditar y registrar las pruebas de calidad de los datos.	OpenMetadata - Data Quality
OpenMetadata	Exploración de la vista de Linaje (Lineage View) para mapear visualmente el flujo extremo a extremo.	OpenMetadata - Lineage View
SingleStore	Documentación de la base de datos para la conexión directa con herramientas de BI como Power BI.	SingleStore - Connect with Power BI-
Power BI	Documentación oficial del conector nativo de Tableau hacia bases SingleStore (antes MemSQL) para vistas certificadas.	Power BI - SingleStore Connector
Datasets Olist	Origen de los datos (órdenes, clientes, reseñas, pagos, etc.) para resolver el problema de abandono en los próximos 90 días.	<i>Kaggle / datos.gob.ec mirror (Archivos CSV)</i>

10.2 Fuentes Metodológicas y Bibliográficas (Arquitectura, ML y Gobierno)

Título de la Fuente	Enfoque Metodológico	Enlace Oficial (Link del recurso)
Managing Data as a Product (Andrea Gioia)	Arquitectura centrada en Productos de Datos, Data Mesh y la especificación de descriptores (DPDS).	<u>Repositorio GitHub con código de ejemplo</u>
Data Governance (John Ladley)	Diseño, despliegue y marcos de operación para la implementación efectiva de gobierno de datos.	<u>Blog de Herramientas de Data Governance, Elsevier Books</u>
The Data Warehouse Lifecycle Toolkit / Microsoft Data	Construcción del modelo dimensional (Tablas de Hechos y Dimensiones, esquemas en estrella) y ecosistema ETL.	<u>Kimball Group - Templates & Recursos, Página Principal</u>

Warehouse Toolkit (Kimball Group)		
Hands-On Machine Learning (Aurélien Géron)	Aplicación práctica de algoritmos de Machine Learning en Python, utilizados para crear modelos predictivos como el de <i>Churn</i> .	<u>Repositorio GitHub</u> , <u>Notebooks interactivos en Colab</u>
El vendedor desafiante (Dixon & Adamson)	Marco teórico para la estructuración del impacto emocional (ej. mostrar el costo financiero de la "Deuda de Datos") ante ejecutivos.	<u>Empresa Activa / Ediciones Urano</u>

11. Cierre

El producto de datos logra transformar la complejidad transaccional de Olist en un activo analítico proactivo. En lugar de limitarse a mostrar reportes de "lo que ya pasó", el modelo de segmentación RFM permite identificar con exactitud qué clientes volverán a comprar en los próximos 90 días y qué categorías específicas (Top 5) están impulsando la fuga de clientes

Confianza Ejecutiva (Data Trust) Garantizada para evitar que la Dirección Comercial perciba el algoritmo predictivo como una "caja negra", el producto no solo entrega un dashboard, sino un ecosistema auditable. A través del linaje trazado en OpenMetadata y la ejecución de reglas de calidad estrictas en SingleStore, se asegura que las anomalías nativas de Olist (como el ~8% de fechas inconsistentes y el ~3% de reseñas nulas) sean aisladas y no contaminen las decisiones ejecutivas.